

DS, Mini Project : ESS 배터리 수명 예측 (DAY2)

DS-MINI-Design · 울산 1반 · 박준형(U015) · 2026-10-02

요약

검증 질문: Day 1에서 고른 초기 $\Delta Q(V)$ 신호가 새로운 실험 배치에서도 수명을 예측하는지 확인했습니다. 정격 용량의 80%에 도달할 때까지의 사이클 수를 예측하는 회귀 문제로 두고, Batch 1 41셀을 학습에, Batch 2 43셀을 필수 테스트에, Batch 3 40셀을 추가 평가에 사용했습니다.

변수와 모델 결정: 초기 $\Delta Q(V)$ 의 로그 분산을 핵심으로 두고, 1~100사이클의 평균 방전 용량 QD와 내부저항 IR을 함께 사용했습니다. 기존 $\Delta Q(V)+QD$ 로그 Ridge의 개발용 CV는 7.59% MAPE, IR을 추가하고 Ridge 규제 강도를 0.1로 낮춘 모델은 7.10%였습니다. 초기 IR의 단순 상관만은 약하지만 기존 두 변수와 겹치지 않는 정보가 있다고 판단했습니다. 선택 모델은 단일 로그 타깃 Ridge이며 앙상블은 아닙니다.

필수 성능: Batch 1 개발용 정책별 CV 7.10%, 정책이 겹치지 않는 hold-out 7.15%, Batch 2 19.39% MAPE입니다. Gap은 Valid-Train +0.06%p, Batch 2-Valid +12.24%p, Batch 2-논문 참고값 9.1% +10.29%p입니다. Batch 3의 추가 평가 MAPE는 10.99%입니다. 이전 2변수 모델의 Batch 2 24.11%보다 낮지만 배치 이동 오차는 남았습니다.

논문 수치의 범위: 과제에서 제시한 9.1%는 논문 초록의 대표 수치입니다. 논문 표에서 전체 Primary test의 MAPE는 Full 모델 14.1%, Discharge 모델 13.0%이며, 논문의 학습 집합은 Batch 1~2를 섞습니다. 이번 과제의 Batch 1 학습 → Batch 2 전체 테스트와 같은 조건으로 읽지 않았습니다.

오차의 방향: Batch 2의 실제 수명 중앙값은 481사이클, 예측 중앙값은 570사이클입니다. 43셀 중 37셀을 길게 봤고, 500사이클 미만 33셀에서는 평균 78사이클 과대예측했습니다. Batch 3의 1,000사이클 초과 19셀은 평균 177사이클 과소예측했습니다. 수치가 개선돼도 같은 방향의 편향이 남아 있습니다.

결론과 한계: 초기 내부저항을 더하자 개발용 CV와 두 평가 배치의 오차가 줄었습니다. 다만 IR 후보는 이전 Batch 2 결과를 본 뒤 탐색했으며, Batch 1의 작은 표본에서 여러 조합을 비교했습니다. 19.39%를 독립적으로 검증된 일반화 성능으로 주장하지 않습니다. 새 배치에서 측정 조건과 수명 기준을 맞춘 뒤 동일한 절차를 다시 시험해야 합니다.

목차

- 01 검증 질문과 데이터 분할
초기 $\Delta Q(V)$ 신호의 배치 간 적용 가능성 · 분석 셀과 수명 목표값 · 정책별 분할과 검증 이력
- 02 초기 변수 비교와 모델 개선
QD-Tavg-IR을 비교한 이유 · 22개 후보의 Batch 1 비교 · 내부저항을 더한 모델을 선택한 근거
- 03 모델 성능과 논문 기준 비교
CV-hold-out-Batch 2 성능과 Gap · 사이클 단위 오차와 논문 비교 범위
- 04 배치별 예측 오차와 분포 이동
Batch 2의 짧은 수명 분포 · Batch 2의 단수명 과대예측 · Batch 3의 장수명 과소예측
- 05 사후 실험과 재검증 계획
후보별 배치 이동 비교 · Batch 2 소수 레이블 보정 · 새 배치에서 다시 검증할 절차
- 06 9.1% 목표 재검토와 추가 실험
논문 성능과 과제 분할의 차이 · 초기 변수와 측정 품질을 바꾼 결과 · 현재 모델을 유지한 이유
- 07 ESS 운영에서의 판단과 제 생각
점검 우선순위에 쓸 수 있는 신호 · 변수를 바꾼 뒤 남은 결론 · 현장 적용 전 개선 순서
- 08 참고 자료

검증 질문과 데이터 분할

초기 $Q(V)$ 신호의 배치 간 적용 가능성

Day 1에서 가장 눈에 띈 것은 초기 방전 용량 곡선 변화였습니다. $\Delta Q(V)$ 로그 분산과 수명의 Spearman 상관은 Batch 1·2·3에서 -0.88~-0.65~-0.76이었습니다. 세 배치에서 방향이 같았기 때문에 이 신호를 모델의 중심에 놓았습니다. 그러나 Batch 1의 최단 수명은 534사이클이고 Batch 2에는 500사이클 미만이 33/43셀입니다. 따라서 Day 2의 질문은 “상관이 있는가”에서 끝나지 않습니다. Batch 1에서 학습한 사이클 수를 Batch 2에도 맞힐 수 있는가를 확인해야 합니다.

초기 온도와 충전 조건도 함께 검토했습니다. 온도 T_{avg} 와 수명의 상관은 Batch 1에서 -0.39, Batch 2·3에서는 +0.09~+0.02였습니다. 충전 정책 강도는 Batch 1에서 $\Delta Q(V)$ 로그 분산과 Pearson 상관이 0.96이었습니다. 저는 두 변수가 도메인에서 의미 있다는 이유만으로 모두 넣지 않고, 추가했을 때 Batch 1의 정책 분리 검증에서 실제로 이득이 있는지 먼저 보았습니다.

분석 셀과 수명 목표값

원논문의 원자료 파일 2017-05-12, 2017-06-30, 2018-04-12를 Batch 1·2·3으로 사용했습니다. 원본에는 각각 46·48·46셀이 있습니다. 공개 전처리 코드에 따라 Batch 1의 80% 종료점 미도달 5셀, Batch 2의 연속 측정 5셀, Batch 3의 노이즈 채널 6셀을 분석 집단에서 제외했습니다. Batch 1 첫 5셀의 수명 레이블에는 이어 측정한 길이 662·981·1,060·208·482사이클을 각각 더했습니다. 다만 방전 용량 곡선은 이어 붙이지 않았으므로 이 5셀의 knee는 Day 1 EDA에서 계산하지 않았습니다. 최종 대상은 41·43·40셀입니다.

목표값 `cycle_life`는 정격 용량의 80%에 도달할 때까지의 사이클 수입니다. 예측 입력은 100사이클까지 확보할 수 있는 값으로 제한했습니다. 후반 용량 곡선이나 knee는 수명 설명에 유용해도 모델에는 넣지 않았습니다. Batch 2의 연속 기록 5셀은 Batch 1의 레이블을 완성하는 데만 쓰고, Batch 2 테스트 집단에서는 제외했습니다. 같은 물리적 셀이 학습과 테스트에 중복되지 않도록 한 처리입니다.

정책별 분할과 검증 이력

Batch 1의 41셀을 충전 정책 단위로 개발용 31셀과 hold-out 10셀로 나눴습니다. 개발용에서 정책별 5분할 `GroupKFold`를 수행했고, 한 정책의 셀이 학습-검증에 동시에 들어가지 않게 했습니다. 결측 대체와 표준화는 각 학습 폴드에서만 맞춥니다. 후보를 고른 뒤 개발용으로 학습한 모델을 hold-out에 적용하고, Batch 1 전체로 다시 학습해 Batch 2를 테스트했습니다. Batch 3은 추가 평가입니다.

보고 표의 Train (Batch 1 CV)는 학습 데이터 자체의 오차가 아니라, 개발용 5개 검증 폴드의 MAPE 평균입니다. Hold-out은 같은 배치에서 충전 정책을 분리한 평가이며, Batch 2는 실험 배치를 바꾼 평가입니다. 두 결과의 차이에는 배치 이동뿐 아니라 학습 셀 수가 31→41개로 바뀐 영향도 포함됩니다. 정책을 분리해도 비슷한 정책끼리의 정보 공유까지 완전히 막을 수는 없습니다.

Day 1의 사전 모델 비교는 Batch 1 전체 41셀로 수행했습니다. 따라서 이번 hold-out 10셀도 이전 탐색 단계에서는 사용했습니다. Day 2의 후보 비교와 변수 제거 실험에는 이 10셀을 넣지 않았지만, 7.15%를 처음부터 한 번도 보지 않은 셀의 검증 성능으로 해석하지는 않겠습니다. 이후 실험에서는 첫 EDA·모델 비교 전에 hold-out을 고정해야 합니다.


Day 1에서 Batch 2·3의 분포를 보았고, 이전 2변수 모델의 Batch 2 결과 24.11%도 확인했습니다. 이번 IR 추가는 그다음에 진행한 사후 탐색입니다. 따라서 Batch 2에서 개선된 수치는 새로운 외부 시험 결과가 아닙니다. 다음에 얻을 새 배치로 같은 모델을 다시 확인해야 합니다.

초기 변수 비교와 모델 개선

$QD \cdot T_{avg} \cdot IR$ 을 비교한 이유

Day 1의 일반 Ridge에서는 $\Delta Q(V)$ 단독 모델이 12.97%, $\Delta Q(V) + QD + T_{avg}$ 모델이 13.27%였습니다. 보조 변수를 넣을수록 좋아질 것이라는 기대와 달랐습니다. Day 2에는 목표값을 로그로 바꾼 같은 Ridge에서 변수 조합을 다시 비교했습니다. 수명은 양수이고 MAPE는 비율 오차를 보므로, 로그 타깃은 검토할 만한 변형이었습니다. 로그로 학습한 예측값은 지수변환해 사이클 수로 되돌렸습니다.

로그 Ridge 입력	Batch 1 개발용 CV MAPE	제 판단
$\Delta Q(V)$ 로그 분산	10.08%	초기 곡선 하나만으로도 기준선보다 낮습니다.
$\Delta Q(V)$ 로그 분산 + 평균 QD	7.59%	용량 수준 정보가 곡선 변화에 없는 부분을 보았습니다.
$\Delta Q(V)$ 로그 분산 + 평균 Tavg	10.50%	온도만 추가해서는 오차가 줄지 않았습니다.
$\Delta Q(V)$ 로그 분산 + 평균 QD + 평균 Tavg	8.07%	온도를 다시 더하자 0.48%p 높아졌습니다.




같은 정책별 CV와 로그 Ridge에서 입력 변수만 바꾼 제거 실험

평균 QD는 1~100사이클의 방전 용량 수준이고 $\Delta Q(V)$ 는 10→100사이클 곡선의 전압별 변화입니다. 둘은 같은 용량 기록에서 나오지만 요약하는 측면이 달라, 이 제거 실험에서는 함께 쓸 근거가 생겼습니다. 온도는 배터리 열화에 중요한 조건이더라도 이번 배치의 예측 변수로는 이득을 확인하지 못했습니다. 이 단계에서 $\Delta Q(V)+QD$ 를 기본 모델로 남겼습니다.

초기 내부저항 IR은 전류가 흐를 때 전압 손실과 관련된 값이므로, 충전 정책표보다 셀의 실제 상태에 가까운 입력이라고 생각했습니다. 그렇다고 IR 하나만으로 수명을 설명할 수 있다는 뜻은 아닙니다. 수명과의 Spearman 상관은 Batch 1·2·3에서 +0.21+0.10+0.21로 약했습니다. 저는 기존 두 변수를 알고도 IR이 오차를 줄이는지 확인했습니다. Batch 1 개발용에서 IR과 $\Delta Q(V)$ 로그 분산의 Pearson 상관은 -0.32, 평균 QD와는 +0.19였습니다. 완전히 독립적인 값은 아니지만 같은 숫자를 반복한 수준도 아닙니다.

추가 비교	Batch 1 개발용 CV MAPE	판단
$\Delta Q(V)+QD, \alpha = 1.0$	7.59%	기존 2변수 기준입니다.
$\Delta Q(V)+QD, \alpha = 0.1$	7.53%	규제 강도만 바꾼 효과는 0.06%p였습니다.
$\Delta Q(V)+QD+IR, \alpha = 1.0$	7.30%	같은 규제 강도에서 IR을 더한 효과가 보였습니다.
$\Delta Q(V)+QD+IR, \alpha = 0.1$	7.10%	IR과 규제 강도를 함께 반영한 현재 모델입니다.
$\Delta Q(V)+QD+\Delta Q$ 평균절댓값, $\alpha = 0.1$	6.66%	CV는 가장 낮았지만 두 ΔQ 요약값의 상관이 0.95로 높습니다.




Batch 1 정책별 CV에서 초기 IR과 ΔQ 요약값을 비교한 추가 실험

IR 모델의 5개 폴드 중 3개에서 기존 모델보다 MAPE가 낮았습니다. 4·5·6분할로 바꾸어도 평균 오차가 기존 모델보다 낮지만, 이 작은 차이를 강한 우위로 보기는 어렵습니다. ΔQ 평균절댓값 후보는 CV가 더 낮았습니다. 그러나 Batch 1 개발에서 로그 분산과 평균절댓값의 Pearson 상관이 0.95라 같은 곡선의 정보를 중복할 가능성이 큼니다. 따라서 CV 최솟값 하나만을 선택 기준으로 삼지 않았습니다. 물리적으로 다른 초기 추정값을 보탠다는 점과 분할별 변동을 함께 고려해 IR 후보를 남겼습니다. 여러 조합을 탐색한 결과이므로 CV 자체도 낙관적일 수 있습니다.

22개 후보의 Batch 1 비교

셀 수가 적고 초기 변수끼리 겹쳐서, 먼저 중앙값 기준선과 규제된 선형 모델을 비교했습니다. 이어 비선형성을 확인하기 위해 작은 트리·Random Forest·Extra Trees·Gradient Boosting·SVR·KNN 등을 같은 개발용 정책 분할에 넣었습니다. IR 모델을 추가해 총 22개 설정을 같은 분할에서 비교했습니다. 아래 표는 의사결정에 영향을 준 대표 후보입니다.

후보	Batch 1 개발용 CV MAPE	EDA와 연결한 해석
중앙값 기준선	24.18%	입력 변수의 효과를 확인할 기준입니다.
일반 Ridge, 3변수($\alpha = 1$)	12.36%	단순한 절대 수명 회귀의 비교점입니다.
Elastic Net, 3변수($\alpha = 0.1$)	12.27%	중복 변수 처리만으로 로그 변환의 이득을 대신하지 못했습니다.
깊이 2 결정트리, 3변수	18.39%	작은 표본에서는 단순 비선형 규칙도 불안정했습니다.
Random Forest, 3변수	12.11%	앙상블의 내부 점수 이득이 확인되지 않았습니다.
로그 Ridge, 3변수	8.07%	로그 타깃은 분명히 개선됐지만 온도는 남은 의문입니다.
로그 Ridge, 3변수+정책 강도	7.90%	정책 변수가 $\Delta Q(V)$ 와 겹칩니다.
로그 Ridge, $\Delta Q(V)$ +QD	7.59%	기존 기준 모델입니다.
로그 Ridge, $\Delta Q(V)$ +QD+IR	7.10%	다른 초기 추정값을 더해 오차를 줄인 후보입니다.



Batch 1 개발용 CV와 정책 분리 hold-out의 후보별 오차

내부저항을 더한 모델을 선택한 근거

기존 2변수 모델은 개발용 CV 7.59%였고, IR 을 더한 모델은 7.10%였습니다. 규제 강도만 1.0에서 0.1로 낮추면 7.53%여서 개선 전부가 α 조정 때문은 아닙니다. T_{avg} 는 배치별 수명 상관이 흔들렸고 정책 강도는 $\Delta Q(V)$ 와 많이 겹쳤습니다. 반면 IR 은 도메인상 셀 상태를 나타내며 기존 두 입력과 완전히 겹치지 않았습니다. 그래서 $\Delta Q(V)$ 로그 분산, 초기 평균 QD , 초기 평균 IR 을 쓰는 로그 Ridge($\alpha = 0.1$)를 현재 제출 모델로 정했습니다. 단일 회귀이며 여러 모델의 예측을 합치지 않습니다.

이 선택은 이전 모델의 Batch 2 성능을 확인한 후에 이뤄졌습니다. Batch 1 개발용 CV의 0.49%p 개선도 표본 31셀과 여러 후보 탐색을 고려하면 확정적인 차이가 아닙니다. Hold-out과 Batch 2·3 점수는 다음 절에서 사후 확인 결과로 적겠습니다. 외부 배치에서 다시 검증될 때까지 보편적인 최적 모델이라고 부르지 않겠습니다.

모델 성능과 논문 기준 비교

CV·hold-out·Batch 2 성능과 Gap

구분	MAPE (%)	비고
Train (Batch 1 CV)	7.10	개발용 31셀, 정책별 5분할 평균
Valid (Batch 1 Hold-out)	7.15	정책이 겹치지 않는 10셀
Test (Batch 2)	19.39	Batch 1 전체로 재학습 후 43셀 평가
Gap (Train-Valid)	+0.06%p	Valid-Train
Gap (Valid-Test)	+12.24%p	Batch 2-Valid
Gap (Target-Test)	+10.29%p	Batch 2-과제의 논문 초록 기준 9.1%
Test (Batch 3)	10.99	추가 평가 40셀
Gap (Batch2-Batch3)	-8.40%p	Batch 3-Batch 2
Gap (Target-Test, Batch 3)	+1.89%p	Batch 3-과제의 논문 초록 기준 9.1%

Gap은 뒤 구간의 MAPE에서 앞 구간의 MAPE를 뺀 퍼센트포인트입니다. Train과 Valid의 차이는 0.06%p로 작지만, Batch 2에서는 Valid보다 12.24%p 높았습니다. 이전 모델의 Batch 2 MAPE 24.11%와 비교하면 4.72%p 줄었습니다. 그러나 이를 ‘과적합이 없어졌다’는 뜻으로 읽지 않습니다. Hold-out은 10셀이고 Day 1 탐색에 노출됐으며, Batch 2도 이전 결과를 본 뒤 다시 평가했습니다. 새 배치에서 절대 수명 수준이 맞는지 여전히 확인해야 합니다.


사이클 단위 오차와 논문 비교 범위

평가 구간	MAE	RMSE
Batch 1 hold-out	108사이클	182사이클
Batch 2	91사이클	106사이클
Batch 3	128사이클	200사이클

MAPE만 보면 Batch 3이 Batch 2보다 훨씬 낮지만, Batch 3의 MAE는 오히려 128사이클로 더 큼니다. 실제 수명이 길면 같은 절대 오차가 더 작은 비율이 되기 때문입니다. 운영에서 점검 시기를 생각하려면 비율과 사이클 수를 함께 봐야 합니다. 원논문의 9.1%는 초록의 대표 수치입니다. 논문 표의 Primary 전체 셀 점수와 분할은 이 과제와 다르므로, +10.29%p는 과제 기준 대비 차이이지 동일 실험 재현 성적표가 아닙니다.

배치별 예측 오차와 분포 이동

Batch 2의 짧은 수명 분포




세 배치의 초기 ΔQ(V) 로그 분산과 실제 수명 분포

$\Delta Q(V)$ 로그 분산 중앙값은 Batch 1 -3.84, Batch 2 -3.52, Batch 3 -4.15입니다. Batch 2에서는 곡선 변화가 상대적으로 크고 실제 수명 중앙값은 481사이클로 짧습니다. Batch 3은 곡선 변화가 상대적으로 작고 수명 중앙값은 965사이클입니다. EDA의 방향은 여전히 의미가 있습니다. 하지만 이 방향이 맞다는 사실만으로 Batch 2의 절대 수명값을 맞혔다고 할 수는 없습니다.

Batch 1에는 534사이클보다 짧은 학습 셀이 없습니다. Batch 2의 43셀 중 33셀은 500사이클 미만입니다. 이는 단순히 이상치 몇 개의 문제가 아니라 평가 집단 대부분이 학습 범위 아래에 있는 상황입니다. 저는 Batch 2 성능 저하의 가장 먼저 확인할 설명을 이 수명 분포의 차이와 예측 수준의 이동으로 잡았습니다. 실험 시기, 정책 구성, 측정 시작 조건이 각각 얼마나 기여했는지는 이 분석만으로 분리할 수 없습니다.


Batch 2의 단수명 과대예측



배치별 실제 수명과 예측 수명, 수명에 따른 잔차

Batch 2의 실제 수명 중앙값은 481사이클, 예측 중앙값은 570사이클입니다. 43셀 중 37셀을 길게 예측했습니다. 500 사이클 미만인 33셀의 평균 편향은 +78사이클입니다. 기존 모델의 +103사이클보다 줄었지만 방향은 같습니다. 실제 수명과 예측 수명의 Pearson 상관은 0.74여서 셀 사이 상대 순서는 일부 따라가지만, 전반적인 예측 수준이 높습니다. 운영에 연결한다면 빨리 열화되는 셀의 점검을 늦추는 방향입니다.

기존 2변수 모델과 셀별 절대비율오차를 맞대어 보니 Batch 2 43셀 중 37셀에서 IR 모델의 오차가 줄었습니다. 한 셀의 우연한 개선으로 평균만 낮아진 결과는 아닙니다. 그러나 같은 37셀을 여전히 길게 예측했다는 점은 오차 크기는 줄었지만 배치 기준의 이동은 해결하지 못했다는 뜻입니다.




Batch 2 셀별 초기 $\Delta Q(V)$ 신호와 실제·예측 수명

가장 크게 틀린 batch2_020은 실제 502사이클을 758사이클로 예측했습니다. 오차는 +256사이클입니다. 한편 최단 수명 148사이클 셀은 184사이클로 예측했습니다. 이 셀의 $\Delta Q(V)$ 로그 분산은 -2.73으로 배치 중앙값 -3.52보다 높아 초기 변화가 두드러집니다. 그러나 극단적으로 짧은 수명의 원인을 이 값이나 충전 정책 하나로 확정할 수 없습니다. 종료 기록과 측정 품질을 따로 확인할 필요가 있습니다.

Batch 3의 장수명 과소예측

Batch 3 MAPE는 10.99%로 Batch 2보다 낮습니다. 그러나 실제 수명이 1,000사이클을 넘는 19셀은 평균 177사이클 짧게 예측했습니다. batch3_038은 실제 1,935사이클을 1,143사이클로 예측해 오차가 -792사이클입니다. Batch 3의 충전 커브 시작 시점은 다른 배치와 다르므로 Qdlin 기반 피쳐의 측정 정렬도 다시 확인해야 합니다. 이 차이가 오차의 원인이라고 단정하지는 않았습니다.



실제 수명 구간별 평균 예측 편향과 셀 수


짧은 수명을 길게 보는 Batch 2와 긴 수명을 짧게 보는 Batch 3은 운영상 반대 방향의 위험입니다. 전자는 필요한 점검을 늦출 수 있고, 후자는 사용 가능한 셀을 너무 일찍 제외할 수 있습니다. 그래서 저는 전체 MAPE 하나보다 수명 구간별 과대·과소예측과 표본 수를 성능 해석에 같이 적었습니다.

사후 실험과 재검증 계획

후보별 배치 이동 비교

22개 설정을 Batch 1 개발용 CV에서 비교한 뒤, 같은 후보들의 hold-out·Batch 2·3 점수도 원인 진단용으로 계산했습니다. 아래 점수는 새 배치의 독립 성능 순위표가 아닙니다. 특히 IR 후보 자체가 이전 Batch 2 결과를 본 뒤 추가됐으므로 현재 개선 폭은 회고적입니다.

후보	Batch 1 CV	Hold-out	Batch 2	Batch 3
로그 Ridge, $\Delta Q(V)+QD+IR$	7.10%	7.15%	19.39%	10.99%
로그 Ridge, $\Delta Q(V)+QD$	7.59%	7.82%	24.11%	11.96%
로그 Ridge, 3변수+정책	7.90%	6.34%	36.50%	20.01%
로그 Ridge, 3변수	8.07%	7.82%	24.67%	12.88%
Random Forest, 3변수	12.11%	17.28%	41.42%	12.38%
Extra Trees, 3변수	11.17%	13.89%	47.69%	10.81%
Elastic Net, 3변수	12.27%	12.35%	38.31%	15.06%
깊이 2 결정트리	18.39%	32.04%	47.91%	15.40%
중앙값 기준선	24.18%	27.73%	86.87%	19.17%




후보들의 Batch 1 CV와 Batch 2·3 MAPE 관계

정책 강도를 더한 로그 Ridge는 Batch 1 CV가 7.90%로 나쁘지 않았지만 Batch 2는 36.50%였습니다. $\Delta Q(V)$ 와 정책 강도의 중복을 걱정한 이유가 실제 새 배치 오차와도 연결됩니다. Extra Trees의 Batch 3 점수는 10.81%로 현재 모델보다 약간 낮지만 Batch 2는 47.69%입니다. 한 배치에서 좋은 모델을 나중에 골라 전체 성능으로 소개하지 않겠습니다. 22개 후보의 Batch 1 CV와 Batch 2 MAPE 순위 Spearman 상관은 0.68, Batch 3과는 0.49로 순위도 완전히 유지되지 않습니다. 후보 설정끼리 비슷하므로 이 수치를 독립 표본의 통계 검정으로 읽지 않았습니다.

Batch 2 소수 레이블 보정

현재 3변수 모델에 대해, Batch 2의 수명값 일부를 추가로 얻었다고 가정해 보정 가능성을 살펴봤습니다. 충전 정책이 겹치지 않게 Batch 2를 보정용 13~15셀과 나머지 평가용으로 나누는 절차를 50회 반복했습니다. 보정용 셀의 실제값과 예측값 사이의 중앙 잔차를 더하거나 중앙 비율을 곱했습니다. 평가용 셀의 수명은 보정값 계산에 사용하지 않았습니다.

방법	반복 평가 평균 MAPE	평균 MAE
무보정	19.25%	91사이클
중앙 잔차 이동	13.56%	62사이클
중앙 비율 보정	10.90%	52사이클



Batch 2 정책 분리 반복 평가의 보정 전후 MAPE

이 결과는 Batch 2의 레이블을 13~15개 더 사용한 별도 실험입니다. 필수 Test 19.39%를 10.90%로 바꿔 적을 수는 없습니다. 50회도 같은 셀을 반복 나눈 것이므로 독립 테스트 50개가 아닙니다. 더구나 Batch 2 전체 레이블로 계산한 비율을 Batch 3에 옮기면 Batch 3 MAPE가 10.99→20.65%로 나빠집니다. 저는 보정의 가능성과 보정값의 배치 의존성을 동시에 확인했습니다.

새 배치에서 다시 검증할 절차

첫째, Batch 3의 Qdlin이 Batch 1·2와 같은 전압 구간과 시작 시점에서 만들어졌는지 원곡선과 기록 메타데이터를 대조해야 합니다. 측정 정의가 다르면 분산값의 차이를 셀 상태 차이로만 읽을 수 없습니다. 둘째, 새 배치의 소수 셀에서 실제 수명 레이블을 얻어 기준 이동을 추정할 수 있는지 검증해야 합니다. 이때 보정용 정책과 평가용 정책은 미리 나눠야 합니다. 셋째, 그 절차를 다음 시기에 수집한 배치에 적용해 점검 우선순위와 사이클 수 오차가 유지되는지 확인해야 합니다. 새 데이터가 없으면 지금의 반복 실험만으로 현장 일반화를 주장할 수 없습니다.

9.1% 목표 재검토와 추가 실험

논문 성능과 과제 분할의 차이

9.1%를 목표로 다시 확인하면서 [논문 표 1](#)과 [저자의 분할 코드](#)를 대조했습니다. 논문 초록은 회귀 테스트 오차 9.1%를 대표값으로 제시하지만, 표의 Primary test 전체 셀 MAPE는 Full 모델 14.1%, Discharge 모델 13.0%입니다. Full 모델의 7.5%는 특정 이상 셀 1개를 제외한 결과입니다. 이 과제의 필수 평가에서는 Batch 2의 43셀을 모두 포함했습니다.

논문의 학습 41셀과 Primary test 43셀은 Batch 1과 2를 섞어 나눈 집합입니다. 과제의 Batch 1 전체 학습 → Batch 2 전체 테스트와 분할이 다릅니다. 이를 확인하려고 현재 3변수 모델을 저자의 혼합 분할에 별도로 적용하니, 43셀의 MAPE는 11.16%였습니다. 그중 Batch 1 출신 21셀은 9.92%, Batch 2 출신 22셀은 12.35%였습니다. 이 수치는 분할 차이를 살펴보는 사후 진단이며 논문 모델을 재현한 점수가 아닙니다. 저는 19.39%와 9.1%의 차이를 모델만의 성능 차이로 설명하지 않겠습니다.

초기 변수와 측정 품질을 바꾼 결과

[논문 보충자료](#)의 방전 곡선 통계량과 초기 용량 변화를 추가했습니다. 용량의 2번째 사이클 값, 초기 기울기, 내부저항의 시작·끝값도 각각 시험했습니다. 아래는 현재 모델과 비교에 중요한 후보입니다. 수치는 모두 MAPE(%)입니다.

Batch 1에서 시험한 변경	개발용 CV	정책 분리 hold-out	Batch 2 전체	판단
현재 ΔQ 분산 + 평균 QD + 평균 IR	7.10	7.15	19.39	제출 모델을 유지했습니다.
평균 QD 대신 2번째 사이클 QD	6.46	8.23	23.58	내부 CV는 낮지만 새 배치 오차가 컸습니다.
논문형 방전 변수 6개 + 로그 Elastic Net	5.75	10.46	23.11	초기 곡선 통계량을 늘려도 Batch 2가 개선되지는 않았습니다.
짧은 수명 학습 셀 가중치 증가	6.97	7.34	19.81	짧은 수명 외삽 시험도 나빠졌습니다.
새 배치의 정답 없이 입력 분포로 학습 가중치 조정	6.94	6.77	19.91	내부 검증 개선이 Batch 2로 이어지지 않았습니다.

논문형 변수의 QD 초기 최댓값을 원본 그대로 계산하면 Batch 1의 두 셀에서 1.54Ah와 2.88Ah로 튜 기록이 반영됐습니다. 이때 정책 분리 hold-out MAPE가 28.00%였습니다. 명목 용량 1.1Ah인 셀에서 이 두 기록을 제외하고 0.5~1.3Ah 범위의 최댓값을 쓰자 10.46%로 내려갔습니다. 같은 처리 후 Batch 2는 23.11%였습니다. 저는 이 결과를 원본 변수의 이상값 민감도를 확인한 것으로 해석했습니다. 이 수정도 검증 셀을 살펴본 뒤 진행했으므로 독립적인 개선 점수로 취급하지 않았습니다.

MathWorks의 재현 예제처럼 시간 공백이 큰 사이클을 빼고 $\Delta Q(V)$ 를 다시 계산했습니다. Batch 1의 15셀에서 값이 바뀌었고 개발용 CV는 7.10→7.39%로 높아졌습니다. Batch 2는 이 방법으로 재평가하지 않았습니다. 기존 수명 레이블과 $\Delta Q(V)$ 는 원자료와 일치해, 계산 오류가 19.39%의 원인이라는 근거는 없었습니다.

현재 모델을 유지한 이유

추가 후보 중에는 Batch 1 내부 CV가 현재 모델보다 낮은 조합이 있습니다. 그러나 정책을 분리한 검증 또는 Batch 2에서 개선이 유지되지 않았습니다. 가장 큰 제약은 Batch 1의 최단 수명이 534사이클인 반면, Batch 2는 43셀 중 33셀이 500사이클 미만이라는 점입니다. Batch 1에 없는 짧은 수명을 외삽해야 하므로, 같은 배치에서 작은 오차가 다른 배치의 작은 오차를 보장하지 않습니다.

이 실험들은 이미 Batch 2 결과를 본 뒤 진행했습니다. Batch 2 정답을 이용해 9%가 나오는 후보를 선택하는 방식으로 제출 점수를 바꾸지 않겠습니다. 현재 필수 성능은 19.39%로 유지합니다. 다음 개선의 근거는 새 배치를 평가용으로 미리 고정하고, 초기 측정 정의와 짧은 수명 셀의 학습 범위를 확보한 뒤 검증하는 절차에서 얻어야 합니다.

ESS 운영에서의 판단과 제 생각

점검 우선순위에 쓸 수 있는 신호

실제 ESS 운영에서 수명이 짧은 가능성이 있는 셀을 일찍 찾으려면 검사 순서를 정하는 데 도움이 됩니다. 이번 분석에서 $\Delta Q(V)$ 변화가 큰 셀은 세 배치 모두 수명이 짧은 방향이었습니다. 저는 이 신호와 초기 IR을 추가 점검 대상을 고르는 단서로는 보겠습니다. 그러나 Batch 2의 짧은 셀을 평균 78사이클 길게 예측한 모델로 교체 시점을 바로 결정할 수는 없습니다. 셀 실험에서 얻은 숫자를 팩의 수명으로 그대로 옮기지도 않겠습니다. 팩에는 셀 편차, 열 관리, BMS 제어와 실제 운전 조건이 더해지기 때문입니다.

변수를 바꾼 뒤 남은 결론

처음 질문은 초기 신호가 수명과 연결되는지였습니다. EDA에서 $\Delta Q(V)$ 가 가장 일관된 관계를 보였고, 평균 QD를 더한 2변수 로그 Ridge의 개발용 CV는 7.59%였습니다. Batch 2에서는 24.11%로 오차가 커졌습니다. 초기 내부저항 IR을 더해 개발용 CV를 7.10%, Batch 2를 19.39%로 낮췄지만 여전히 논문 참고값과 거리가 있습니다. 제 판단에서 중요한 것은 초기 곡선 변화가 수명과 연결된다는 관찰과 다른 배치의 절대 수명값을 맞추는 문제를 구분하는 일입니다. IR은 그 간격을 줄였지만 없애지 못했습니다.

온도를 제거한 결정도 같은 흐름입니다. 배터리 열화에는 온도가 중요하다는 도메인 지식이 있습니다. 그런데 이번 초기 Tavg는 배치별 수명 상관이 흔들렸고, 2변수 로그 Ridge에 추가하자 개발용 MAPE가 7.59→8.07%로 올라갔습니다. 그래서 입력에서 뺐습니다. 반면 IR은 단순 상관이 약해도 기존 입력과 함께 썼을 때 오차가 줄었습니다. 도메인에서 중요해 보이는 변수와 이번 자료에서 추가 예측력이 있는 변수는 직접 검증해 구분해야 한다고 생각합니다.

현장 적용 전 개선 순서

제가 다음에 먼저 할 일은 부스팅 모델을 더 세게 튜닝하는 것이 아닙니다. IR을 추가해도 Batch 2의 37/43셀을 과대에 축했습니다. 우선 원곡선의 측정 정렬과 수명 레이블 기준을 점검하겠습니다. 그다음 새 배치의 일부 레이블로 보정하는 절차를 사전에 고정하고, 별도의 다음 배치로 평가하겠습니다. 마지막으로 짧은 수명의 과대예측이 운영상 더 위험하다면 그 구간의 오차를 모델 선택 지표에 추가하겠습니다. 어떤 셀을 얼마나 늦게 점검하게 만드는지까지 설명할 수 있어야 이 예측을 ESS 의사결정에 연결할 수 있습니다.

참고 자료

- [Severson 외, *Data-driven prediction of battery cycle life before capacity degradation*](#): 초록의 9.1% 대표 수치와 표 1의 평가 집합별 성능.
- [논문 보충자료](#), [저자의 분할 코드](#): 변수 정의와 논문의 혼합 분할 확인.
- [MathWorks의 배터리 수명 예측 예제](#): 시간 공백 사이클 처리 방식 참고.
- [원논문 데이터 처리 코드](#): 제외 셀과 연속 측정 셀 확인.
- [MIT-Stanford 원자료](#): 세 배치 실험 자료.
- [미국 에너지부 ESS 연구개발](#), [NREL 저장 시스템 구성 자료](#): ESS 구성과 운영 맥락 참고.